

Типы локальных экономик России: кластеризация атрибутированной сети муниципалитетов

Методологический отчёт. Онлайн-конкурс СберИндекса 2026, трек «Кластеризация». Код, конфигурации и интерактивный лендинг — в репозитории проекта (site/index.html).

0. Коротко

Задача. Найти типы локальных экономик среди муниципальных образований (МО) России, проследить, как МО переходят между типами, и объяснить типы экономически.

Метод ДУЭТ в одной фразе. Муниципалитет описывается двумя взглядами: *чем он живёт* (зарплаты, отрасли, население — это атрибуты узла) и *как в нём тратят* (траектории безналичных трат жителей за 24 месяца — это рёбра сети). Тип — группа МО, похожих и по экономической базе, и по образу трат.

Результат.

- **Шесть устойчивых типов** на 2 016 МО: промышленные и крупные города — 371, районы бюджетной экономики — 622, столичные агломерации и центры услуг — 302, ресурсные территории севера и востока — 192, транспортные узлы — 185, аграрные районы — 344. $K = 6$ — наибольшее число типов, при котором каждый тип воспроизводится на подвыборках (худший тип — 0,86 при пороге 0,75; при $K = 7$ — 0,68).
- **Сеть работает.** KEFRiN (признаки + сеть) — первый в рейтинге выбора и в общем рейтинге 13 методов, включая три графовые нейросети. Против k-means он меняет тип у 11% МО: доля соседей по тратам из того же типа растёт с 51% до 53% при почти той же компактности (силуэт 0,261 против 0,285).
- **Типы осмысленны.** Тип объясняет 71% разброса доли общепита и 59% доли продовольствия; типы только по Росстату, без трат, — 68% и 58%: связь «экономика → траты» есть в данных, а не создана моделью. Типы, построенные **без** зарплаты, объясняют 73% её разброса: проверка не замкнута на признаки.
- **Динамика проверена на синтетике с известной истиной:** метод находит 87% настоящих переходов за два месяца и почти не даёт ложных. Вес памяти $\alpha = 0,5$ независимо подтверждён AFFECT ($\alpha \approx 0,55$). 88 МО сменили тип насовсем; как группа смены значимы (в 3,6 раза сильнее, чем у стабильных МО), отдельные — кандидаты.
- **Ритм.** У 290 МО свой сезонный ритм трат, повторившийся в оба года; каждая трактовка проверена составом корзины (§8).

Что нового. Атрибуты — производство и доходы, рёбра — потребление; поправка «место работы ≠ место жительства» для районов Москвы и Петербурга; восемь правил ребра с измеренным влиянием на типы; протокол выбора метода с контрольной группой; калиброванная синтетика для динамики; линза ритма; лендинг с паспортом МО и экономическими двойниками.

Критерий	Где в отчёте
Простое объяснение методологии (15%)	§0, §1 (схема), формулы — в приложении А
Сетевая и атрибутивная структура (15%)	§3, §4
Сравнение методов (15%)	§5 (13 методов: 8 в рейтинге выбора, 5 контрольных), §7 (динамика), приложение Б
ICVI: SW, CH, S_Dbw, AVI, AVU, MQ (15%)	§5.2 (включая BasicMQ), приложения А и Б
Интерпретация, воспроизводимость, обоснованность (30%)	§6–§9, §11
Визуализация (10%)	лендинг site/index.html , рис. 1–6

1. Схема решения

1. **Данные** → панель 2 016 МО × 24 месяца × 6 категорий трат + Росстат + доступность рынков (`s02_panel.py`).
2. **Атрибуты узла** — экономическая база МО и уровень трат (§3).
3. **Рёбра** — сходство траекторий трат; сравнены восемь правил (`s03_edges.py`, `s07_edge_effect.py`, §4).
4. **Кластеризация** — восемь методов, шесть индексов качества, рейтинг Алескерова; выбор K по устойчивости (`s06_methods.py`, `s05_choose_k.py`, §5).

- 5. **Интерпретация** — профили по Миркину, формулы типов (FCA), паттерны Алескерова–Мячина, внешняя проверка (`s11_types.py`, §6).
- 6. **Динамика** — 24 помесечные сети, эволюционная кластеризация, проверка на синтетике, переходы, события MONIC (`s08_dynamics.py`, `s09_synthetic.py`, `s12_transitions.py`, §7).
- 7. **Ритм** — сезонные подписи МО (`s10_rhythm.py`, §8).

Все гиперпараметры — в `configs/pipeline.yaml`, имена типов — в `configs/typology.yaml`; весь конвейер — `python scripts/run.py`.

Метод ДУЭТ

Наша связка шагов оформлена как единый метод **ДУЭТ** (DUET — DUal-view Evolutionary Typology, «типология по двум взглядам с эволюционным отслеживанием»). Отдельные блоки опираются на опубликованные работы (KEFRiN — Shalileh, Mirkin, 2022; эволюционная кластеризация — Chakrabarti et al., 2006; AFFECT — Xu et al., 2014), а их сочетание, разделение ролей данных и протокол проверки предложены и проверены в этой работе.

- 1. **Разделение взглядов.** Атрибуты узла — только экономическая база («чем живёт»: Росстат, доступность рынков, уровень трат); рёбра — только поведение трат («как тратит»: DTW по траекториям корзины за 24 месяца). Одни и те же данные не учитываются дважды, поэтому вклад сети измерим (§4.3).
- 2. **Совместная типология.** KEFRiN с косинусным расстоянием: у каждого типа два центра — в признаках и в строках модулярностной матрицы; вес сети ξ уравнивает разброс двух пространств. К выбирается как наибольшее, при котором устойчив каждый тип (Жаккар Хеннига $\geq 0,75$).
- 3. **Эволюционное отслеживание.** 24 помесечные сети; срез сглаживается памятью α с тёплым стартом от прошлого месяца. α подтверждена дважды: калиброванной синтетикой с известной истиной и адаптивным AFFECT.
- 4. **Протокол выбора с контрольной группой.** Правило выбора задано до сравнения (рейтинг Алескерова по z-оценкам шести ICVI и бутстрапу); контрольные методы — графовые нейросети, Louvain, Ward со связностью — добавлены после выбора и показаны отдельно; рейтинг проверен правилами Борда и Коупленда, BasicMQ и внешней сетью.

2. Данные

Источник	Что взято	Покрытие
СберИндекс, потребительские безналичные расходы на уровне МО (архив хакатона, CC BY-SA 4.0)	средние траты жителя в месяц, Р: всего и 5 категорий	2 190 МО, 2023-01...2024-12; 2 016 с полной историей
СберИндекс, индекс доступности рынков	объём доступного внешнего рынка, 0–1000	99,4% МО панели
СберИндекс, автодорожные связи МО	расстояние по дорогам между центрами МО	5,9 млн пар
СберИндекс, справочник и границы МО	названия, тип, регион, ОКТМО, центры, полигоны	все МО панели
СберИндекс, индекс покупательской мобильности (API)	средняя дальность покупок, км	279 МО (СЗФО) — только для проверки
Росстат, БД показателей МО через «Если быть точным» (CC BY 4.0)	население (всё и городское), среднемесячная зарплата и численность работников по разделам ОКВЭД2, 2024 г.	99% МО

Шестая часть корзины — «прочее» = все траты – пять категорий. Публичная выгрузка API ключуется по названию МО (одноимённые МО разных регионов неразличимы), поэтому основой служит архив хакатона с `territory_id`. В панели нет 12 регионов (в том числе Краснодарский край, Ростовская область, Крым, Дагестан). Росстат не публикует занятость в отраслях с малым числом предприятий, поэтому доли шести укрупнённых отраслей в сумме дают в среднем 0,92.

Поправка «место работы ≠ место жительства». Росстат считает работников по месту работы. Во внутригородских территориях Москвы и Петербурга это бессмысленно: в «спальном» Дачном 2,5 тыс. рабочих мест на 70 тыс. жителей, и структура «занятости» описывает несколько местных организаций. Жители таких районов работают по всему городу, поэтому 242 внутригородским территориям присвоены общегородские доли отраслей и зарплата (взвешенно по числу работников).

3. Атрибуты узла: «чем живёт» МО

Блок	Признаки	Зачем
Доходы	логарифм средней зарплаты	уровень оплаты труда
Размер и урбанизация	логарифм населения, доля горожан	город или село, крупный или малый
Положение	логарифм индекса доступности рынков	удалённость, логистика
Структура занятости	доли: сельское хозяйство; добыча; промышленность, энергетика и строительство; транспорт; прочие рыночные услуги; бюджетный сектор	экономическая специализация (транспорт выделен отдельно: иначе железнодорожные узлы с 25–50% занятых в транспорте выглядят как «сервисные» столицы)
Уровень трат	логарифм трат на жителя минус медиана по всем МО в том же месяце	«сколько тратят» без инфляции и общероссийской сезонности

Все признаки стандартизованы (z-оценки), хвосты обрезаны на $\pm 4\sigma$: иначе несколько добывающих МО с долей добычи выше 70% доминировали бы в расстояниях.

Почему структура трат — не в атрибутах, а в рёбрах. Тип локальной экономики — это прежде всего её база: что производят и сколько зарабатывают. Образ трат описывает, как эта база превращается в жизнь людей. Мы кладём базу в атрибуты, а потребление — в связи, и требуем, чтобы тип был согласован с обоими. Бонус: структура трат не входит в атрибуты, и её связь с типами можно проверить на контрольной типологии без данных о тратах (§6.3).

4. Рёбра: правило «экономической близости»

Одна сеть для типологии, 24 сети для динамики. Тип локальной экономики — устойчивая характеристика: экономическая база меняется годами, а не месяцами. Поэтому сама типология строится на одной сети, где ребро сравнивает *траектории* трат за все 24 месяца (DTW): так связь отражает образ трат, а не случайности одного месяца, и сезон не путается с типом. Помесячные сети (§7) строятся из корзины каждого месяца и отвечают на другой вопрос — *кто и когда сменил тип*. Разделение задано заранее: типология — по полной траектории, динамика — по месячным срезам, связанным памятью α .

4.1. Восемь правил

Для каждого МО строится вектор или ряд потребления (8 каналов по месяцам: уровень трат, CLR-координаты шести долей корзины, остаток кривой Энгеля). CLR — центрированный логарифм отношения: доли в сумме дают 1, и обычные расстояния между ними искажены (геометрия Айчисона). Правила ребра:

- **косинус** профиля трат (средние за 24 месяца) — «тратят одинаково»;
- **гауссово ядро** с локальным масштабом (Zelnik-Manor & Perona) — то же, но нелинейно;
- **корреляция рядов** (Пирсон по 24 месяцам $\times$ 8 каналов без собственного среднего МО) — «движутся вместе»;
- **лаговая корреляция** — максимум корреляции уровня трат по сдвигам ± 2 месяца — «один МО опережает другой»;
- **DTW** — динамическое выравнивание траекторий (окно 2 месяца) — «одинаковая траектория с допуском по времени»;
- **дороги** — $\exp(-d/200 \text{ км})$ по автодорожным расстояниям СберИндекса — «соседи»;
- **сходство экономической базы** — косинус атрибутов (контрольное правило: дублирует атрибуты);
- **слияние SNF** (Similarity Network Fusion, Wang et al., Nature Methods 2014) трёх взглядов — «как тратят» (DTW), «чем живут» (экономическая база) и «где» (дороги). Каждая сеть итеративно диффундирует по kNN-структуре двух других: остаются связи, поддержанные несколькими взглядами, а видные только в одном затухают.

Разрежение одно для всех: каждый МО связан с 15 самыми похожими (kNN, объединение), вес ребра — сходство.

4.2. Что измеряет каждое правило

Правило	рёбер внутри региона	похожесть соседей: зарплата	уровень трат	доля маркетплейсов	занятость в добыче	модулярность
косинус профиля трат	22%	0,79	0,91	0,86	0,21	0,74
гауссово ядро	23%	0,83	0,94	0,90	0,23	0,74
корреляция рядов	27%	0,71	0,71	0,54	0,21	0,57
лаговая корреляция ± 2 мес.	17%	0,52	0,61	0,35	0,11	0,64
DTW траекторий (основное)	24%	0,84	0,94	0,88	0,23	0,69
близость по дорогам	71%	0,80	0,75	0,63	0,34	0,87
сходство экономической базы (контроль)	22%	0,91	0,82	0,57	0,88	0,80
слияние SNF: траты + база + дороги	64%	0,89	0,87	0,76	0,55	0,82

«Похожесть соседей» — корреляция показателя на двух концах ребра. Модулярность — у разбиения Leiden на этом графе.

Выводы. (1) Правила потребления делятся на два семейства, которые почти не пересекаются по рёбрам: *профиль* (косинус, ядро, DTW; общих рёбер 43–57%) и *со-движение* (корреляции; общих рёбер с профилем 4–9%). SNF действительно сочетает взгляды (общих рёбер: с DTW 18%, с базой 19%, с дорогами 42%), но география в нём перевешивает (64% рёбер внутри региона), а сообщества получаются такими плотными, что сеть подавляет признаки: KEFRiN на SNF-графе даёт силуэт 0,069 и почти другое разбиение (ARI с основным 0,24). Поэтому SNF оставлен как альтернатива, а не как основа: экономический тип не должен сводиться к «соседи по карте». (2) Соседи по профилю трат похожи по зарплате (0,77–0,81), хотя зарплата в рёбрах не участвует, — потребление действительно отражает экономику. (3) Дорожная сеть на 71% состоит из рёбер внутри региона: она описывает географию. (4) У 49% рёбер лаговой сети лучший сдвиг ненулевой, но на 24 месяцах это в основном шум: лаговая сеть слабее всех связана с экономикой (похожесть по зарплате 0,45).

Выбор: DTW. DTW сочетает уровень и структуру корзины, допускает сдвиг сезонных пиков на месяц-два (у северных и южных МО они приходятся на разные месяцы) и даёт высокую похожесть соседей по зарплате (0,81) и по уровню трат (0,94).

4.3. Как правило ребра меняет типологию

Таблица — в приложении Д.1. Правило ребра заметно влияет на результат. Близкие по смыслу правила дают близкие типологии (косинус профиля — почти та же, что DTW), со-движение рядов и лаговая корреляция сдвигают границы типов умеренно, а гауссово ядро, дороги и контрольный граф «сходства базы» — сильно. Ни одно правило не делает типы региональными: ARI с регионом $\approx 0,09$.

Что сеть добавляет к признакам. KEFRiN на DTW-графе и k-means на тех же признаках согласуются с ARI 0,78: сеть меняет тип у 221 МО (11%). Доля соседей по тратам, попавших в тот же тип, растёт по всем МО с 51% до 53%, а у сменивших тип — с 32% до 48%: сеть переносит МО к тем, на кого он похож по образу жизни.

5. Методы, индексы качества и выбор числа типов

5.1. Методы

- **Только признаки:** k-means, Ward, смесь гауссиан (GMM).
- **Только сеть:** спектральная кластеризация, Leiden (разрешение подбирается под K).
- **Признаки и сеть вместе:** KEFRiN (Shalileh & Mirkin, 2022) с евклидовым (KEFRiN-e) и косинусным (KEFRiN-c) расстоянием; CANUS (Shalileh, 2025) — код автора, скачивается скриптом на закреплённом коммите.
- **Глубокие графовые нейросети (GNN)** — современный «нейросетевой» ответ на ту же задачу, тоже видят и признаки, и сеть (свои компактные реализации на PyTorch по статьям, [src/uklad/gnn.py](#)): GAE + k-means (Kipf & Welling, 2016) — графовый автоэнкодер сжимает МО в 16-мерный вектор, по которому можно восстановить его связи, затем k-means; DAEGC (Wang et al., IJCAI 2019) — то же с графовым вниманием и самообучением на собственных мягких метках; DMoN (Tsitsulin et al., JMLR 2023) — GNN, которая напрямую максимизирует модулярность со штрафом за слипание кластеров.

KEFRiN своими словами. Это k-means, у которого у каждого кластера два центра: в пространстве признаков и в пространстве связей. МО относится к кластеру, к обоим центрам которого он в сумме ближе всего. Строка связей

МО — это строка модулярностной матрицы $B = A - k\mathbf{1}/2m$: сколько у МО связей с каждым другим МО *сверх ожидаемого случайно*. Вес сети ξ уравнивает суммарный разброс двух пространств. Косинусная версия сравнивает направления векторов, а не длины: для строки связей это «с кем связан», а не «сколько связей». Реализация — своя, по формулам статьи ([src/uklad/partition.py](https://github.com/uklad/partition.py)): у кода авторов нет лицензии.

5.2. Индексы качества (ICVI)

- В пространстве признаков: **SW** (силуэт, $\uparrow$), **CH** (Калински–Харабаш, $\uparrow$), **S_Dbw** (разброс плюс плотность между кластерами, $\downarrow$).
- В сети: **AVI** (средняя изолированность — доля веса связей, оставшаяся внутри кластера, $\uparrow$), **AVU** (средняя «слитость» пар кластеров, $\downarrow$), **MQ** — модулярность Q ($\uparrow$).

Формулы — в приложении А. AVI, AVU и модулярность сверены с кодом библиотеки Pattern Лаборатории СберИндекс: расхождение не больше 10^{-15} на случайных графах. Под MQ мы понимаем модулярность Ньюмана — Гирвана (так метрика называется в Pattern). Модульное качество Манкоридиса в варианте TurboMQ на неориентированном графе вырождается в $K \cdot AVI$ и ничего к AVI не добавляет, поэтому считаем и исходный **BasicMQ** (Mancoiridis et al., 1998): средняя связность внутри типа μ_i/N_i^2 минус средняя связность между типами $\epsilon_{ij}/(2N_iN_j)$. Он штрафует межтиповые связи и учитывает размеры типов. Если в рейтинге заменить модулярность на BasicMQ, KEFRiN-с остаётся 1-м по пороговому агрегированию и 1-м по Борда ([outputs/method_comparison/ranking_mq_basic.csv](https://github.com/uklad/partition.py)).

Индексы разных методов несравнимы «в лоб»: AVI случайного разбиения $\approx 1/K$, CH растёт на сферических кластерах. Поэтому для каждого индекса считаем и **z-оценку против перестановки меток** (50 перестановок при тех же размерах кластеров): насколько разбиение лучше случайного.

5.3. Сравнение методов при $K = 6$

Метод	место (Алескерова)	место (Борда)	SW $\uparrow$	CH $\uparrow$	S_Dbw $\downarrow$	AVI $\uparrow$	AVU $\downarrow$	MQ $\uparrow$	бутстрап $\uparrow$
KEFRiN-с (признаки+сеть)	1	1	0,261	613	0,559	0,509	0,511	0,342	0,94
KEFRiN-е (признаки+сеть)	2	2	0,283	653	0,499	0,485	0,491	0,325	0,93
k-means (признаки)	3	3	0,285	656	0,484	0,460	0,484	0,303	0,97
CANUS (признаки+сеть)	4	5	0,188	477	0,569	0,481	0,544	0,343	0,59
Ward (признаки)	5	4	0,225	551	0,563	0,476	0,487	0,302	0,54
GMM (признаки)	5	6	0,121	370	0,663	0,449	0,526	0,267	0,64
Leiden (сеть)	7	6	0,081	287	0,765	0,854	0,508	0,652	0,50
спектральная (сеть)	7	8	0,047	242	0,627	0,853	0,527	0,605	0,78

В таблице — сырые значения индексов; места считаются не по ним, а по z-оценкам (таблица ниже). Бутстрап — 20 подвыборок по 80% МО; для CANUS — 5 (один запуск идёт около 5 минут). Места — пороговое агрегирование Алескерова (Aleskerov, Yakuba, Yuzbashev, 2007) по z-оценкам шести ICVI и бутстрап-устойчивости: каждый критерий ставит методу оценку 1/2/3 (лучшая, средняя, худшая треть), выше тот, у кого меньше «троек», при равенстве — меньше «двоек». В отличие от суммы мест (Борда), провал по одному индексу нельзя «купить» успехом по другому.

Выбор метода и честная оговорка. Правило выбора задано до сравнения: основной метод — первый по пороговому агрегированию. Это **KEFRiN-с**; правило Борда ставит его первым. Но честно скажем: **три лидера почти равны**. KEFRiN-с уступает k-means в компактности (силуэт 0,261 против 0,285) и устойчивости (0,94 против 0,97), выигрывая в согласии с сетью (MQ 0,342 против 0,303, AVI 0,509 против 0,460). Разбиения тройки близки: ARI KEFRiN-с с k-means 0,78, с KEFRiN-е 0,82. Все три — варианты «k-means по признакам с учётом сети или без неё», и выводы о типах от выбора между ними почти не зависят. Ещё одна оговорка: число типов (§5.4) и косинусная метрика подбирались на основном методе, что даёт ему небольшое преимущество; k-means при том же K устойчив не хуже (бутстрап 0,97). Сетевые методы (Leiden, спектральная) максимизируют модулярность, но их типы не компактны в признаках ($SW \approx 0$) и неустойчивы; Ward и GMM неустойчивы; CANUS на наших данных уступает KEFRiN почти по всем индексам и неустойчив (бутстрап 0,59, по 5 подвыборкам).

Устойчивость рейтинга. Рейтинг пересчитан в восьми вариантах (Алескерова или Борда $\times$ с AVU или без $\times$ с бутстрапом или без): KEFRiN-с первый в 8 из 8. Таблица вариантов и z-оценки — в приложении Б. Третье правило, Коупленда (метод побеждает другой, если лучше по большинству критериев), ставит KEFRiN-с 2-м, а первым — k-

means: попарно k-means чуть чаще выигрывает по компактности. Это то же наблюдение «лидеры почти равны», только с другой стороны (outputs/method_comparison/ranking_copeland.csv).


Проверка на внешней сети. Разбиения всех 13 методов оценены на сети, которая в их построении не участвовала: 15 ближайших МО по железной дороге (данные СберИндекса о связях, 1 262 МО со связями). Выше всех ожидаемо сетевые методы и нейросети — их типы во многом географические. KEFRiN-с занимает 7-е место, k-means — 11-е: сеть трат делает типы заметно связнее и на независимой сети (средняя z-оценка AVI, AVU и MQ 50 против 38), хотя география в рёбрах не участвует (outputs/method_comparison/external_railway.csv).

Почему не нейросеть. Пять методов добавлены после выбора как внешний контроль: DAEGC, Ward со связностью, DMoN, GAE + k-means, Louvain. Правило выбора основного метода задано до их добавления, поэтому рейтинг выбора выше — по восьми исходным методам. В общем рейтинге всех 13 методов (таблица ниже) KEFRiN-с остаётся на 1-м месте (делит его с KEFRiN-е, DAEGC); места относительно (трети по каждому критерию), и новые участники сдвигают пороги. По сути нейросети ведут себя как сетевые методы: у лучшей из них, DAEGC, модулярность MQ 0,632 против 0,342 у KEFRiN-с, но силуэт 0,068 против 0,261 и устойчивость на бутстрапе 0,62 против 0,94. Нейросеть группирует МО по тому, с кем они связаны, а не по тому, чем они живут, и от подвыборки к подвыборке даёт заметно разные типы. Для экономической типологии это хуже: у типа должен быть понятный портрет по признакам, и он не должен зависеть от случайного зерна. KEFRiN задаёт вес сети явно (ξ), а его центры читаются как профиль типа. Ward с ограничением связности — другой простой способ учесть сеть — неустойчив (бутстрап 0,54).

Полная таблица всех методов — в приложении Б.3.

5.4. Число типов


Таблица — в приложении Д.2. Индексы SW и CH почти монотонно падают с K, S_Dbw падает — внутреннего оптимума у них нет, и это ожидаемо для данных без резких границ. **Индексы здесь противоречат друг другу, и это нужно сказать прямо:** силуэт лучше всего при K = 4, CH, AVI и модулярность — при K = 3, а S_Dbw и AVU всё время улучшаются с ростом K. Свести их в одно «лучшее K» нельзя без произвольных весов, поэтому решающим критерием выбрана устойчивость, которая не зависит от формы кластеров. Поэтому K выбирается по **устойчивости**: 20 подвыборок по 80% МО, ARI с полным разбиением и для каждого кластера — средний максимальный Жаккар (Hennig, 2007; > 0,75 — устойчивый паттерн). **K = 6 — наибольшее K, при котором устойчив каждый тип** (рис. 2): худший тип 0,86, при K = 7 — 0,68. Устойчивы и меньшие K, но берём наибольшее устойчивое: цель — как можно более подробная экономическая типология, а каждый лишний тип должен воспроизводиться на подвыборках. Так при K = 6 отделились транспортные узлы: при K = 5 (тот же метод и seed) 110 из 185 из них сливаются с ресурсными территориями, остальные расходятся по аграрным, промышленным и бюджетным. Порог 0,75 — общепринятый у Хеннига; в таблице для справки дан и более строгий 0,85.



6. Типы

Типы локальных экономик (KEFRiN, K = 6)

Столичные агломерации и центры услуг · 302 МО



Ресурсные территории Севера и Востока · 192 МО



Промышленные и крупные города · 371 МО



Транспортные узлы · 185 МО



Районы бюджетной экономики · 622 МО



Аграрные районы · 344 МО



Каждая карта — один тип: его МО выделены цветом, остальные — серым.
Москва и Петербург — сотни мелких МО, на карте страны почти не видны; см. лендинг.

Каждая карта — один тип: его МО выделены цветом, остальные — серым.
Москва и Петербург — сотни мелких МО, на карте страны почти не видны; см. лендинг.

6.1. Профили

Тип (медианы)	МО	траты, Р/мес	еда, %	общепит, %	маркетпл., %	зарплата, Р	население	горожане, %	доступность	с/х, %	добыча, %	промышл., %	бюджет, %
Столичные агломерации и центры услуг	302	46 240	33,0	7,5	11,9	131 928	77 377	100	526	0,0	0,4	14,6	21,5
Ресурсные территории Севера и Востока	192	35 377	43,0	3,7	11,0	113 301	24 354	70	202	0,5	19,5	13,5	32,6
Промышленные и крупные города	371	29 095	42,2	4,0	13,8	66 408	61 143	88	336	0,4	0,0	38,0	34,6
Транспортные узлы	185	25 284	46,1	2,3	13,7	65 633	25 382	65	272	0,9	0,0	12,5	43,2
Районы бюджетной экономики	622	21 309	48,3	1,6	15,1	47 810	13 628	0	312	0,0	0,0	5,3	62,8
Аграрные районы	344	21 240	47,5	1,7	14,6	52 984	18 616	0	326	19,5	0,0	6,5	45,9

Профили типов по Миркину: отклонение среднего типа от среднего по стране, %																
Столичные агломерации и центры услуг	+61	-25	+120	-11	+25	+15	+98	+94	+80	+56	-91	-85	+9	+18	+156	-42
Ресурсные территории Севера и Востока	+28	-1	+13	-23	-12	-16	+47	-33	+16	-39	-52	+724	-1	+20	-28	-25
Промышленные и крупные города	+2	-4	+21	+0	-0	+2	-11	+136	+53	+3	-63	-74	+134	-19	-12	-19
Транспортные узлы	-9	+4	-24	-2	-8	-7	-12	-45	+18	-19	-41	-54	-19	+225	-32	-5
Районы бюджетной экономики	-24	+9	-45	+9	-3	-2	-36	-71	-49	-10	-54	-86	-58	-54	-31	+40
Аграрные районы	-24	+8	-41	+7	-5	+2	-31	-59	-59	-3	+302	-71	-40	-33	-37	+3
траты на жителя, доля продовольствия, доля общепита, доля маркетплейсов, доля транспорта, доля здоровья, зарплата, население, доля горожан, доступность рынков, занятость: сельское хоз., занятость: добыча, занятость: промышленность, занятость: транспорт, занятость: рыночные услуги, занятость: бюджетный сектор																

- **Столичные агломерации и центры услуг** — Москва, Петербург, ближнее Подмосковье и крупнейшие сервисные центры (Екатеринбург, Тюмень, Владивосток, Хабаровск, Иркутск). Половина занятых — в рыночных услугах, зарплата почти втрое выше, чем в районах бюджетной экономики; доля общепита 7,5% трат (вчетверо выше, чем на селе), продовольствия — 33%: закон Энгеля в чистом виде.

- **Ресурсные территории Севера и Востока** — Сургут, Нижневартовск, Норильск, Якутск, Камчатка, Сахалин: добыча — 20% занятых, зарплата 113 тыс. ₽, худшая доступность рынков; маркетплейсов меньше всех (11% трат) — граница доставки.
- **Промышленные и крупные города** — Новосибирск, Казань, Нижний Новгород, Уфа и сотни промышленных городов: обрабатывающая промышленность — 38% занятых, траты немного выше средних.
- **Транспортные узлы** — железнодорожные и портовые города и районы: Тайгинский, Боготол, Ртищевский, Коношский, Няндомский районы, Находка, Тайшет. Каждый пятый работник — в транспорте (медиана по стране 5%). Пока транспорт был частью «рыночных услуг», эти МО попадали к столицам; выделенный в атрибуты, он даёт отдельный, устойчивый тип.
- **Районы бюджетной экономики** — самый массовый тип (622 МО): 63% рабочих мест — бюджетные (школы, больницы, администрации), самые низкие зарплаты, на продовольствие — почти половина корзины.
- **Аграрные районы** — каждый пятый работник в сельском хозяйстве; траты на уровне бюджетных районов (на 15% ниже медианы страны), зато доля маркетплейсов одна из самых высоких.

Формулы типов в терминах анализа формальных понятий и паттерны Алескерова–Мячина — в приложении В.

6.2. Внешняя проверка

Проверка на отложенных признаках. Зарплата, занятость и население входят в признаки модели, поэтому то, что типы «объясняют зарплату», само по себе ничего не доказывает. Чтобы проверка не была замкнутой, типология строилась заново **без** одного блока признаков, и затем проверялось, объясняют ли такие типы показатель, которого модель не видела (`scripts/s23_validation.py`, `outputs/validation/held_out.csv`). Типы, построенные без зарплаты, объясняют 73% разброса зарплаты (с зарплатой в модели — 76%); без занятости — в среднем 30% разброса долей занятых по отраслям; случайные разбиения тех же размеров — меньше 1%. Все 11 отложенных показателей объясняются значимо лучше случайного ($p < 0,01$). Значит, типы улавливают экономическую базу МО через остальные признаки и сеть трат, а не повторяют её по построению.

Таблица — в приложении Д.3. η^2 — доля разброса показателя, объяснённая типами. Структура трат не входит в атрибуты, но входит в рёбра (DTW), поэтому для честной проверки рядом дана контрольная типология: k-means только по признакам Росстата и доступности рынков, без уровня трат и без сети — она не видит трат вовсе. Индекс мобильности — отдельный набор СберИндекса, в модели не участвует.

Контрольная типология объясняет структуру трат почти так же (общепит 68% против 71%, продовольствие 58% против 59%): то, что столицы тратят на общепит в разы больше, а бюджетные районы — почти половину на еду, следует из экономической базы МО; сеть добавляет к этому различия в доле транспорта и маркетплейсов.

Индекс покупательской мобильности (медиана, км): столичные агломерации и центры услуг — 4,8 км, промышленные и крупные города — 1,2 км, ресурсные территории севера и востока — 0,8 км, транспортные узлы — 0,6 км, аграрные районы — 0,6 км, районы бюджетной экономики — 0,5 км. Он убывает вместе с урбанизацией типа.

6.3. Кто уходит в отрыв

Тип — это ещё и уровень жизни. Медианные траты на жителя каждого типа относительно медианы России по месяцам (`scripts/s13_checks.py`, среднее за год, чтобы сезон не мешал):

Таблица — в приложении Д.4. Разрыв между самым богатым и самым бедным типом за год вырос с 97 до 101 п. п. (бутстрап по МО внутри типов, 1000 повторов: изменение от +2,9 до +4,9 п. п., 95% интервал при фиксированной типологии; неопределённость самих типов он не учитывает — рост значим, но невелик): столичные агломерации и центры услуг уходят вперёд, аграрные районы отстают сильнее. Разброс логарифма трат между МО (σ -сходимость) растёт с 0,314 до 0,325: неравенство между муниципалитетами за два года не сокращается. Тип объясняет 72% этого разброса (в оба года) — почти всё неравенство в тратах лежит между типами, а не внутри них.

7. Динамика типов

Коротко. 24 помесечные сети, три способа отслеживания; вес памяти $\alpha = 0,5$ выбран по таблице вариантов и подтверждён дважды: на синтетике с известной истиной и адаптивным методом AFFECT, который сам выбирает $\alpha \approx 0,55$.

Помесячные сети. Для месяца t атрибуты — экономическая база (постоянна) и уровень трат месяца t ; рёбра — kNN по сходству корзины месяца t (скользящее среднее за 3 месяца, чтобы разовые всплески не рвали связи).

Три способа отследить типы.

- 1. Независимо по месяцам: KEFRiN на каждом месяце, метки сопоставляются венгерским алгоритмом.
- 2. **Эволюционная кластеризация** (Chakrabarti, Kumar, Tomkins, 2006): кластеризуется сглаженный срез $\tilde{Y}_t = \alpha \cdot \tilde{Y}_{t-1} + (1-\alpha) \cdot Y_t$, $\tilde{P}_t = \alpha \cdot \tilde{P}_{t-1} + (1-\alpha) \cdot P_t$ с тёплым стартом от меток прошлого месяца. 2а. **Адаптивная память AFFECT** (Xu, Kliger, Hero, Data Min. Knowl. Disc. 2014): то же сглаживание, но α подбирается в каждом месяце из данных как оптимальная усадка к истории, $\alpha_t^* = \Sigma \text{var}(W_t) / (\Sigma \text{var}(W_t) + \Sigma (\Psi_{t-1} - E[W_t])^2)$; E и var оцениваются внутри типов прошлого месяца. Шум месяца велик по сравнению со сдвигом от истории — памяти больше.
- 3. Temporal Leiden — многослойная модулярность (Mucha et al., 2010), только сеть.

Смена типа засчитывается как **устойчивая**, если и старый, и новый тип держатся не меньше трёх месяцев.

Способ	AMI соседних месяцев	смен в месяц	МО без смен	устойчивых переходов	доля устойчивых	SW (медиана)	MQ (медиана)	типов
независимо по месяцам	0,955	1,40%	88,2%	166	26%	0,262	0,319	6
эволюционный KEFRiN, $\alpha=0.25$	0,982	0,48%	93,8%	164	74%	0,260	0,322	6
эволюционный KEFRiN, $\alpha=0.5$	0,984	0,44%	93,9%	151	74%	0,260	0,323	6
эволюционный KEFRiN, $\alpha=0.75$	0,989	0,31%	94,6%	122	85%	0,259	0,325	6
эволюционный KEFRiN, адаптивный α (AFFECT)	0,985	0,42%	94,1%	146	76%	0,260	0,324	6
temporal Leiden, $\omega=0.5$	0,747	20,31%	0,9%	3551	38%	-0,027	0,728	18
temporal Leiden, $\omega=1.0$	0,833	9,05%	32,4%	2118	50%	-0,027	0,721	11

При независимой кластеризации 1,4% МО меняют тип каждый месяц, и только 26% смен устойчивы — это шум. Память $\alpha = 0,5$ снижает долю смен до 0,44% в месяц (на 68%), 74% из них устойчивы, а качество каждого месяца почти не меняется (SW 0,260 против 0,262, MQ 0,323 против 0,319). Temporal Leiden дробит МО на много мелких сообществ с отрицательным силуэтом. Сравнение с ним неравное: число сообществ Leiden задать нельзя (получается 11–18 вместо 6), поэтому его строка показывает другой подход, а не проигрыш при равных условиях.

Проверка выбора α данными. $\alpha = 0,5$ выбрана по таблице вариантов, то есть вручную. AFFECT подбирает вес истории сам, без нашего участия, и получает α от 0,50 до 0,58 (медиана 0,55): данные сами выбирают примерно ту же память. Результат AFFECT почти совпадает с основным (ARI меток за 24 месяца 1,00), поэтому основным оставлен более простой вариант с постоянной α . Есть и вторая причина: AFFECT оптимизирует точность оценки среза, а не скорость обнаружения перехода. На спокойных данных он копит память и замечает настоящий переход позже, чем постоянная $\alpha = 0,5$ (проверяется в `tests/test_pipeline.py` на синтетической панели).

Проверка на синтетике с известной истиной (`s09_synthetic.py`). На реальных данных нельзя узнать, какие смены настоящие, поэтому способы отслеживания сравнены на синтетике, откалиброванной по реальной типологии: центры типов и устойчивые отклонения МО — из данных, ежемесячный шум уровня трат — как в реальных рядах; в 12-м месяце 5% МО по-настоящему переходят в ближайший тип. 800 МО, 3 повтора, два уровня шума.

Шум	Способ	NMI с истиной	ложных смен на МО	мигранты найдены сразу	через 2 мес.	через 4 мес.
калиброванный	независимо	0,77	3,35	65%	58%	52%
калиброванный	эволюционный, $\alpha=0.25$	0,84	0,10	81%	89%	91%
калиброванный	эволюционный, $\alpha=0.5$	0,83	0,06	46%	87%	89%
калиброванный	эволюционный, $\alpha=0.75$	0,83	0,02	16%	62%	81%
шум ×2 по всем признакам	независимо	0,70	4,54	69%	78%	65%
шум ×2 по всем признакам	эволюционный, $\alpha=0.25$	0,79	1,33	78%	89%	90%
шум ×2 по всем признакам	эволюционный, $\alpha=0.5$	0,81	0,75	48%	87%	88%
шум ×2 по всем признакам	эволюционный, $\alpha=0.75$	0,81	0,31	17%	59%	83%

Память нужна: без неё метод не отличает переход от шума (3,4 ложных смен на МО за два года). Чем больше α , тем меньше ложных смен, но тем позже замечается настоящий переход. $\alpha = 0,5$ через два месяца находит 87% настоящих переходов ($\alpha = 0,25$ — 89%) и даёт на 38% меньше ложных смен, чем $\alpha = 0,25$.

События MONIC (Spiliopoulou et al., 2006) между январём 2023 и декабрём 2024: все 6 типов «выживают», распадов и слияний нет. Это содержательный результат: экономическая структура страны за два года не перестроилась, менялись отдельные пограничные МО.

Направленные и возвратные переходы. Правило « ≥ 3 месяцев» отсекает шум, но не сезонность: северный город может полгода жить в одном типе и к зиме вернуться в свой. Поэтому переходы разделены (s12_transitions.py): тип МО в начале (мода января–марта 2023) и в конце (мода октября–декабря 2024) различаются — направленный переход, совпадают — возвратный.

Таблица направленных переходов по парам типов — в приложении Г.1.

Из 123 МО, менявших тип, 88 сменили его насовсем, 35 вернулись. **Насколько эти смены надёжны.** Для каждого МО, сменившего тип насовсем, «отрыв» к новому типу (разница расстояний до центров старого и нового типа в пространстве KEFRiN) сравнен с тем же показателем у МО того же исходного типа, которые тип не меняли; точка смены выбирается по данным, поэтому статистика — максимум по всем точкам разрыва (outputs/validation/transitions_significance.csv). По отдельности значимы 28 из 88 переходов при 4,4 ожидаемых случайно (биномиальный $p \approx 10^{-15}$); медианный отрыв у сменивших тип в 3,6 раза больше, чем у не менявших. **Как группа смены реальны, но после строгой поправки на множественность (Бенджамини — Хохберг, 5%) ни один отдельный переход не доказан.** Поэтому конкретные МО из таблицы переходов — кандидаты для проверки, а не установленные факты. Направленные переходы объясняются динамикой относительного уровня трат: МО, поднимающиеся по лестнице типов (к крупным городам и агломерациям), как правило, прибавили к своему уровню трат относительно страны, опускающиеся — потеряли.

Общий сдвиг, не меняющий типов, — **волна маркетплейсов**: медианная доля маркетплейсов выросла с 9,3% до 19,2% трат, доля продовольствия снизилась с 45,3% до 42,4%. На лендинге это видно в «ландшафте Энгеля»: облако МО опускается, а каждый декабрь прыгает вправо (траты на 20% выше обычного месяца).




8. Линза ритма: когда тратят

Ритм МО — помесечные траты за вычетом общероссийского месяца и собственного линейного тренда, усреднённые по двум годам. Своим ритм признаётся, если (1) профиль 2023 г. коррелирует с профилем 2024 г. сильнее 95-го перцентиля перестановочного нуля (те же корреляции для случайных пар «2023 одного МО — 2024 другого»; порог 0,64) и (2) амплитуда выше медианы. Таких МО 290 (14%). Их профили сгруппированы k-means (K по силуэту).

Таблица — в приложении Д.5.

Линза ритма: четыре типа собственного сезонного ритма (повторился в 2023 и 2024 гг.)



Арктический ритм — самый сильный сигнал в данных: в июле траты на 17% выше обычного, общепит — на 43%.

Проверка трактовок. Разные причины сезонности оставляют разный след в корзине: завоз поднимает продовольствие, приток людей — услуги (общепит, здоровье), сезонная добыча связана с долей занятых в добыче. Ниже — средний профиль ритма в его пиковый месяц по каждой категории, той же методикой, что и сам ритм (отклонение от общероссийского месяца за вычетом собственного тренда МО, $\times 100$; `scripts/s13_checks.py`). Поэтому «все траты» и «общепит» здесь совпадают с числами выше, а размах в таблице ритмов (пик минус спад) больше пика.

Состав корзины в пиковый месяц по каждой трактовке — в приложении Г.2.

- **Арктический июль** — не завоз: продовольствие почти не растёт, а общепит, здоровье, маркетплейсы и транспорт — на 20–45%. Это похоже на приток людей: навигация, вахты, возвращение из отпусков, летние работы. Альтернатива, которую по нашим данным не исключить: летом растёт доля безналичных расчётов (приезжие платят картой) — для различения нужны данные о числе клиентов, их в открытом наборе нет.
- **Северо-восточный август.** Мы предполагали сезонную добычу (золото, артели) — версия **не подтвердилась**: из 39 МО 18 — сельские улусы Якутии (Амгинский, Чурапчинский, Таттинский), у медианного МО занятых в добыче нет. Растут общепит (+23%) и здоровье (+16%), продукты — нет; след тот же, что у Арктики, только на месяц позже и слабее.
- **Летний пик** — слабый (+4%) и неоднородный: треть его МО (43 из 130) — ресурсные территории Севера (ЯНАО, Мурманская область, Коми, Сахалин), остальные — сельские районы Алтая, Карелии, Кировской и Костромской областей. Общий след — летний рост общепита и транспорта; «туризм и дачи» объясняет только сельскую часть, единой трактовки мы не даём. В таблице ритмов примеры — самые повторяемые МО, поэтому в них попали северные города.
- **Зимний пик** слабый (+2% в январе), его мы не интерпретируем.

9. Ограничения

Где наш метод не лучше простых. k-means на тех же признаках устойчивее на подвыборках (0,97 против 0,94), компактнее (силуэт 0,285 против 0,261) и выигрывает по правилу Коупленда. Сетевые методы и нейросети сильнее по модулярности. Наш выбор — компромисс: типы почти так же компактны, как у k-means, и при этом согласованы с сетью трат. Если нужна только компактность по признакам, k-means достаточно.

- 24 месяца — один полный годовой цикл: сезонность оценивается по двум повторениям, лаговые связи статистически слабы.
- Траты — модельная оценка СберИндекса (поправка на демографию и активность клиентов); «прочее» — остаток.
- Нет 12 регионов; Росстат засекречивает занятость в малых отраслях; контекст Росстата — годовой и фиксирован на 2024 г.
- Индекс мобильности покрывает только Северо-Западный округ.
- Типы ретроспективны: стандартизация использует все 24 месяца.

10. Литература

Shalileh S., Mirkin B. Community partitioning over feature-rich networks using an extended K-means method // Entropy. 2022. · Shalileh S. A filtered gradient descent clustering method to recover communities in attributed networks // IEEE Access. 2025. · Shalileh S., Antonov E., Tsyplakova D. Profiling consumption using attributed network clustering // Complex Networks & Their Applications XIV. 2026. · Biswas A., Biswas B. Defining quality metrics for graph clustering evaluation // Expert Systems with Applications. 2017. · Halkidi M., Vazirgiannis M. Clustering validity assessment: finding the optimal partitioning of a data set // ICDM. 2001. · Rousseeuw P. Silhouettes // J. Comput. Appl. Math. 1987. · Caliński T., Harabasz J. A dendrite method for cluster analysis // Comm. Stat. 1974. · Newman M., Girvan M. Finding and evaluating community structure in networks // Phys. Rev. E. 2004. · Mancoridis S. et al. Using automatic clustering to produce high-level system organizations of source code // IWPC. 1998. · Aleskerov F., Yakuba V., Yuzbashev D. A «threshold aggregation» of three-graded rankings // Math. Social Sciences. 2007. · Алескеров Ф. Т., Белоусова В. Ю., Егорова Л. Г., Миркин Б. Г. Анализ паттернов в статике и динамике // Бизнес-информатика. 2013. · Мячин А. Л. Pattern analysis in parallel coordinates based on pairwise comparison of parameters // Automation and Remote Control. 2019. · Ganter B., Wille R. Formal Concept Analysis. Springer, 1999. · Kuznetsov S. O. On stability of a formal concept // Ann. Math. Artif. Intell. 2007. · Mirkin B. Clustering: A Data Recovery Approach. CRC, 2012. · Hennig C. Cluster-wise assessment of cluster stability // CSDA. 2007. · Chakrabarti D., Kumar R., Tomkins A. Evolutionary clustering // KDD. 2006. · Mucha P. et al. Community structure in time-dependent, multiscale, and multiplex networks // Science. 2010. · Spiliopoulou M. et al. MONIC: modeling and monitoring cluster transitions // KDD. 2006. · Traag V. et al. From Louvain to Leiden // Sci. Rep. 2019. · Aitchison J. The statistical analysis of compositional data. 1986. · Sakoe H., Chiba S. Dynamic programming algorithm optimization for spoken word recognition // IEEE TASSP. 1978. · Zelnik-Manor L., Perona P. Self-tuning spectral clustering // NIPS. 2004. · Xu K., Kliger M., Hero A. Adaptive evolutionary clustering // Data Min. Knowl. Disc. 2014. · Wang B. et al. Similarity network fusion for aggregating data types on a genomic scale // Nature Methods. 2014. · Kipf T., Welling M. Variational graph auto-encoders // NIPS Workshop. 2016. · Wang C. et al. Attributed graph clustering: a deep attentional embedding approach // IJCAI. 2019. · Tsitsulin A. et al. Graph clustering with graph neural networks // JMLR. 2023. · Blondel V. et al. Fast unfolding of communities in large networks // J. Stat. Mech. 2008.

10а. Источники идей и что сделано самостоятельно

Что	Источник	Как использовано
KEFRiN (кластеризация признаков и сети)	Shalileh, Mirkin, 2022	своя реализация по формулам статьи (src/uklad/partition.py); код авторов не используется
CANUS	Shalileh, 2025	код автора (github.com/Sorooshi/CANUS, коммит 754622a), скачивается скриптом, в репозиторий не включён
AVI, AVU, MQ	библиотека Pattern Лаборатории СберИндекс	своя реализация, сверена с Pattern до 10^{-15} (tests/test_quality.py)
Эволюционная кластеризация, AFFECT	Chakrabarti et al., 2006; Xu, Kliger, Hero, 2014	своя реализация (src/uklad/tracking.py)
SNF, GAE, DAEGC, DMoN	Wang et al., 2014; Kipf, Welling, 2016; Wang et al., 2019; Tsitsulin et al., 2023	свои компактные реализации (graphs.py, deep.py)
Пороговое агрегирование, паттерны, FCA	Алескеров и др.; Мячин; Ganter, Wille; Кузнецов	своя реализация
Leiden, Louvain, k-means, Ward, GMM, спектральная	leidenalg, igraph, scikit-learn	библиотеки

Самостоятельно: постановка «атрибуты — производство и доходы, рёбра — потребление», поправка «место работы ≠ место жительства» для районов Москвы и Петербурга, сравнение восьми правил ребра и их влияния на типологию, протокол выбора метода (рейтинг выбора и контрольные методы), калиброванная синтетика для проверки динамики, линза ритма с перестановочным тестом, интерпретация типов и лендинг.

11. Воспроизводимость

```
pip install -r requirements.txt
python scripts/run.py           # скачивание (SHA-256), панель, графы, методы, динамика, интерпретация, рисунки, лендинг
python scripts/report.py       # этот отчёт: report/uklad_methodology.md и .pdf
pytest -q tests                 # проверки индексов качества, DTW, лаговой корреляции
```

Контрольные суммы: `python scripts/s19_checksums.py` записывает SHA-256 всех файлов `outputs/` в `outputs/CHECKSUMS.sha256`, `python scripts/s19_checksums.py --check` после повторного прогона показывает, какие файлы не совпали байт в байт.

Seed = 42 во всех случайных шагах; гиперпараметры — `configs/pipeline.yaml`; CANUS — коммит 754622a. Все числа и таблицы этого отчёта подставляются из `outputs/` при сборке (`scripts/report.py`). Протокол проверки в свежей копии репозитория, со скачиванием данных с нуля, — `docs/reproduce_check.md`.

Приложение А. Формулы индексов качества

Обозначения: K кластеров $C_1 \dots C_K$, центры c_k , общий центр $\bar{c}$, N объектов; A — симметричная взвешенная матрица смежности; $S_{ab} = \sum_{i \in C_a} \sum_{j \in C_b} A_{ij}$ (внутренние рёбра входят дважды); $out_a = \sum_{b \neq a} S_{ab}$; $2m = \sum_{ab} S_{ab}$.

- **SW** = $(1/N) \sum_i (b_i - a_i) / \max(a_i, b_i)$, a_i — среднее расстояние до своего кластера, b_i — до ближайшего чужого.
- **CH** = $[tr B / (K-1)] / [tr W / (N-K)]$, $tr B = \sum_k |C_k| \|c_k - \bar{c}\|^2$, $tr W = \sum_k \sum_{i \in C_k} \|x_i - c_k\|^2$.
- **S_Dbw** = $Scat + Dens_{bw}$; $Scat = (1/K) \sum_k \|\sigma(C_k)\| / \|\sigma(X)\|$; $Dens_{bw} = 1/(K(K-1)) \sum_{k \neq l} dens(u_{kl}) / \max(dens(c_k), dens(c_l))$, $dens(u)$ — число точек $C_k \cup C_l$ в шаре радиуса $stdev = (1/K) \cdot \sqrt{\sum_k \|\sigma(C_k)\|}$ вокруг u , u_{kl} — середина центров.
- **AVI** = $(1/K) \sum_a S_{aa} / \sum_b S_{ab}$.
- **AVU** = $(1/K) \sum_a \sum_{b \neq a} S_{ab} / (out_a + out_b - S_{ab})$ (нормировка — как в Pattern).
- **MQ** (модулярность) = $\sum_a [S_{aa} / 2m - (\sum_b S_{ab} / 2m)^2]$.
- **BasicMQ** = $(1/K) \sum_a S_{aa} / (2N_a^2) - (2/(K(K-1))) \sum_{a < b} S_{ab} / (2N_a N_b)$; N_a — число МО в типе a .
- **MQ Манкоридиса** = $\sum_a S_{aa} / (S_{aa} + out_a)$.
- **z-оценка** = (индекс – среднее по перестановкам) / ст. отклонение по перестановкам; для S_{Dbw} и AVU знак обращён.

Приложение Б. Детали сравнения методов

Б.1. Почему места считаются по z-оценкам. Сырые индексы зависят от размеров кластеров: метод, который делает один огромный и несколько мелких типов, получает «хороший» S_{Dbw} или AVU почти даром. Поэтому каждый индекс сравнивается со случайной перестановкой тех же меток (те же размеры типов, случайные МО): $z = (\text{индекс} - \text{среднее по перестановкам}) / \text{стандартное отклонение}$, знак выбран так, что больше — лучше. z-оценка говорит, *насколько разбиение лучше случайного с теми же размерами*. Отсюда расхождения с сырой таблицей: например, по сырому S_{Dbw} k-means лучше KEFRiN-c (0,484 против 0,559), но по z-оценке KEFRiN-c дальше от случайного (66,1 против 56,3).

Метод	z SW	z CH	z S_Dbw	z AVI	z AVU	z MQ
KEFRiN-c (признаки+сеть)	44,9	1 634,9	66,1	125,7	10,4	130,8
KEFRiN-e (признаки+сеть)	46,9	1 719,8	56,1	122,5	11,1	124,5
k-means (признаки)	46,6	1 847,7	56,3	111,0	11,2	114,3
CANUS (признаки+сеть)	30,2	1 275,1	68,1	116,6	−13,8	123,8
Ward (признаки)	38,1	1 617,1	45,7	116,6	16,0	113,2
GMM (признаки)	22,5	1 314,8	69,3	110,7	3,4	111,2
Leiden (сеть)	14,1	1 012,4	30,8	233,8	1,6	209,0
спектральная (сеть)	6,9	818,8	20,2	255,7	−44,8	188,8

Б.2. Устойчивость рейтинга. Место метода зависит от того, как свести шесть индексов в одно число. Поэтому рейтинг пересчитан в восьми вариантах: правило Алескерова или Борда × с индексом AVU или без × с бутстрап-устойчивостью или без. KEFRiN-c занимает первое место в 8 из 8 вариантов:

Метод	Алескеров: с AVU, с бутстрапом	Борда: с AVU, с бутстрапом	Алескеров: с AVU, без бутстрапа	Борда: с AVU, без бутстрапа	Алескеров: без AVU, с бутстрапом	Борда: без AVU, с бутстрапом	Алескеров: без AVU, без бутстрапа	Борда: без AVU, без бутстрапа	первых мест
KEFRiN-с (признаки+сеть)	1	1	1	1	1	1	1	1	8
KEFRiN-e (признаки+сеть)	2	2	2	1	2	2	2	2	1
k-means (признаки)	3	3	3	3	4	3	4	3	0
CANUS (признаки+сеть)	4	5	4	6	3	4	3	4	0
Ward (признаки)	5	4	4	4	6	7	5	6	0
Leiden (сеть)	7	6	7	5	8	6	7	4	0
GMM (признаки)	5	6	6	7	5	7	6	8	0
спектральная (сеть)	7	8	8	8	7	5	7	7	0

Б.3. Все 13 методов, включая контрольные.

Метод (все 13)	место, Алескеров	место, Борда	SW ↑	MQ ↑	AVI ↑	бутстрап ↑
KEFRiN-с (признаки+сеть)	1	2	0,261	0,342	0,509	0,94
KEFRiN-e (признаки+сеть)	1	3	0,283	0,325	0,485	0,93
DAEGC (GNN)	1	6	0,068	0,632	0,797	0,62
Ward со связностью (признаки+сеть)	4	5	0,184	0,349	0,512	0,54
DMoN (GNN)	5	1	0,070	0,653	0,819	0,63
k-means (признаки)	6	4	0,285	0,303	0,460	0,97
GMM (признаки)	7	9	0,121	0,267	0,449	0,64
Ward (признаки)	8	7	0,225	0,302	0,476	0,54
GAE + k-means (GNN)	9	8	0,065	0,634	0,816	0,52
CANUS (признаки+сеть)	10	11	0,188	0,343	0,481	0,59
Louvain (сеть)	11	9	0,064	0,645	0,857	0,52
спектральная (сеть)	12	13	0,047	0,605	0,853	0,78
Leiden (сеть)	13	12	0,081	0,652	0,854	0,50

Приложение В. Дополнительные описания типов

В.1. Формулы типов (анализ формальных понятий)

Каждый показатель разбит на интервалы («верхняя четверть», «ниже медианы» и т. д.). Для каждого типа ищется понятие FCA — набор условий, общих для группы МО, — с наибольшей точностью (какая доля МО, удовлетворяющих условию, принадлежит типу) при покрытии не ниже 20%. Устойчивость понятия по Кузнецову (2007) — доля случайных подмножеств его МО, сохраняющих то же описание (оценка Монте-Карло): высокая устойчивость значит, что описание не держится на нескольких МО.

Тип	Формула типа	точность	покрытие	устойчивость
Столичные агломерации и центры услуг	зарплата: верхняя четверть и доля горожан: верхняя четверть и доступность рынков: верхняя четверть	98%	80%	0,36
Ресурсные территории Севера и Востока	доля маркетплейсов: нижняя четверть и зарплата: верхняя четверть и население: нижняя четверть	94%	25%	0,73
Промышленные и крупные города	доля горожан: верхняя четверть и занятость в промышленности: верхняя четверть и городской округ	88%	35%	1,00
Транспортные узлы	траты на жителя: выше медианы и доля общепита: ниже медианы и занятость в транспорте: верхняя четверть	80%	24%	0,82
Районы бюджетной экономики	траты на жителя: ниже медианы и занятость в сельском хозяйстве: ниже медианы и занятость в бюджетном секторе: верхняя четверть	99%	32%	0,41
Аграрные районы	траты на жителя: нижняя четверть и доступность рынков: выше медианы и занятость в сельском хозяйстве: верхняя четверть	89%	29%	0,97

Формулы ресурсных территорий и транспортных узлов включают показатели трат (мало маркетплейсов; высокие траты при малой доле общепита) — это след сети трат: KEFRiN собрал в эти типы МО, похожие и образом потребления.

В.2. Паттерны Алескерова–Мячина

Порядково-инвариантная паттерн-кластеризация группирует МО по *порядку* показателей, без метрики: два МО в одном паттерне, если у них одинаково упорядочены пять долей корзины (нормированных ранг-процентилем по стране). Получилось 134 паттерна, 28 крупных (≥ 20 МО) покрывают 56% МО. Паттерн «общепит > здоровье > транспорт > маркетплейсы > продовольствие» почти целиком состоит из столичных агломераций и крупных городов; паттерны, где маркетплейсы или продовольствие на первом месте, — из районов бюджетной экономики и аграрных районов. Согласие паттернов с типами умеренное: порядок трат различает город и село, но не различает ресурсный и бюджетный районы — для этого нужна экономическая база.

Приложение Г. Таблицы динамики и ритма

Г.1. Направленные переходы

Направленный переход	МО	изменение уровня трат (медиана)	примеры
Столичные агломерации и центры услуг → Промышленные и крупные города	15	+5,1%	Лермонтов, Жуковский, Тарусский, Гатчинский, Кировский, Тосненский
Промышленные и крупные города → Столичные агломерации и центры услуг	14	+4,4%	Красноярск, Владивостокский, Хабаровск, Иркутск, Калининград, Гурьевский
Транспортные узлы → Ресурсные территории Севера и Востока	12	+4,1%	Сортавальский, Верхнеколымский, Могочинский, Артемовский, Дальнереченский, Спасск-Дальний
Районы бюджетной экономики → Аграрные районы	9	-4,2%	Ардатовский, Черемшанский, Киясовский, Родинский, Табунский, Куртамышский
Промышленные и крупные города → Районы бюджетной экономики	6	-7,4%	Агидель, Ядринский, Ахтубинский, Мамоновский, Верхнекамский, Духовщинский
Аграрные районы → Районы бюджетной экономики	3	+3,9%	Первомайский, Славский, Крутинский
Ресурсные территории Севера и Востока → Промышленные и крупные города	3	+3,6%	Учалинский, Жигаловский, Полярные Зори
Транспортные узлы → Районы бюджетной экономики	3	-6,7%	Юрьянский, Алапаевск, Асиновский
Районы бюджетной экономики → Ресурсные территории Севера и Востока	3	+13,9%	Майминский, Мегино-Кангаласский, Ульчский
Промышленные и крупные города → Ресурсные территории Севера и Востока	3	+5,4%	Каларский, Уссурийский, Невьянский
Транспортные узлы → Промышленные и крупные города	2	+4,7%	Мариинский, Тогучинский
Ресурсные территории Севера и Востока → Районы бюджетной экономики	2	-9,5%	Малышевский, Пластовский
Аграрные районы → Промышленные и крупные города	2	+6,3%	Минераловодский, Искитимский
Ресурсные территории Севера и Востока → Аграрные районы	2	-5,9%	Игринский, Каракулинский
Транспортные узлы → Аграрные районы	2	-4,7%	Сармановский, Курагинский
Промышленные и крупные города → Аграрные районы	1	-10,3%	Слободской
Аграрные районы → Столичные агломерации и центры услуг	1	+10,4%	Приозерский
Районы бюджетной экономики → Промышленные и крупные города	1	+6,6%	Конаковский
Районы бюджетной экономики → Транспортные узлы	1	-3,7%	Ольховский
Районы бюджетной экономики → Столичные агломерации и центры услуг	1	+16,9%	Светлогорский
Промышленные и крупные города → Транспортные узлы	1	+1,9%	Абакан
Ресурсные территории Севера и Востока → Столичные агломерации и центры услуг	1	+0,4%	Сургут

Г.2. Проверка трактовок ритма

ритм	МО	пиковый месяц	все траты, %	продовольствие, %	общепит, %	здоровье, %	маркетплейсы, %	транспорт, %	добыча > 5% занятых, доля МО	то же по стране
Летний пик	130	7	+3,7	+1,5	+7,3	+3,2	+1,8	+5,9	25%	10%
Зимний пик	101	1	+2,3	+0,8	+2,8	+1,6	+3,2	+2,0	9%	10%
Арктический июль	20	7	+17,0	+2,2	+43,5	+45,3	+27,9	+22,2	50%	10%
Северо- восточный август	39	8	+7,4	+1,7	+23,1	+15,5	+3,4	+3,0	31%	10%

Приложение Д. Дополнительные таблицы

Д.1. Как правило ребра меняет типологию

Граф в KEFRiN	ARI с основной типологией	ARI с регионом	SW	AVI (свой граф)	MQ (свой граф)
сходство экономической базы (контроль)	0,86	0,07	0,265	0,914	0,719
корреляция рядов	0,92	0,08	0,266	0,403	0,245
косинус профиля трат	0,93	0,08	0,262	0,485	0,333
DTW траекторий (основное)	1,00	0,08	0,261	0,509	0,342
лаговая корреляция ±2 мес.	0,87	0,07	0,261	0,397	0,261
гауссово ядро	0,40	0,08	0,089	0,800	0,591
близость по дорогам	0,78	0,08	0,255	0,508	0,350
слияние SNF: траты + база + дороги	0,24	0,10	0,069	0,915	0,722
без сети (k-means)	0,78	0,06	0,285	0,460	0,303

Д.2. Устойчивость при разном числе типов

K	SW	CH	S_Dbw	AVI	AVU	MQ	бутстрап ARI	худший тип (Хенниг)	типов со строгим Жаккардом > 0,85
3	0,279	732	0,732	0,793	0,667	0,427	0,98	0,97	3
4	0,285	675	0,677	0,694	0,550	0,419	0,96	0,95	4
5	0,245	645	0,590	0,578	0,544	0,362	0,94	0,93	5
6	0,261	613	0,559	0,509	0,511	0,342	0,94	0,86	6
7	0,241	560	0,518	0,513	0,514	0,359	0,84	0,68	4
8	0,241	537	0,470	0,489	0,509	0,362	0,81	0,58	3
9	0,201	499	0,441	0,471	0,507	0,366	0,78	0,66	4
10	0,193	466	0,417	0,442	0,504	0,360	0,71	0,41	2

Д.3. Внешняя проверка: доля объяснённого разброса

Показатель	η^2 , итоговые типы	η^2 , типы только по Росстату	МО
доля продовольствия	0,59	0,58	2016
доля общепита	0,71	0,68	2016
доля маркетплейсов	0,17	0,09	2016
доля транспорта	0,22	0,20	2016
доля здоровья	0,25	0,20	2016
отклонение от кривой Энгеля	0,16	0,09	2016
индекс покупательской мобильности (СберИндекс)	0,54	0,52	279

Д.4. Траты на жителя по типам

Тип	2023, % к медиане России	2024
Столичные агломерации и центры услуг	82,8	85,8
Ресурсные территории Севера и Востока	44,2	40,8
Промышленные и крупные города	14,2	17,3
Транспортные узлы	2,3	1,8
Районы бюджетной экономики	– 14,2	– 14,7
Аграрные районы	– 14,3	– 15,3

Д.5. Группы сезонного ритма

Ритм	МО	месяц пика	размах трат (пик – спад)	регионы	примеры (самые повторяемые)
Летний пик	130	7	7%	Алтайский край (13); Кировская область (9); Республика Карелия (8); Костромская область (8)	Новый Уренгой, Надымский, Воркута, Муравленко, Горно-Алтайск, Кош-Агачский
Зимний пик	101	1	4%	Свердловская область (8); Республика Башкортостан (5); Ставропольский край (5); Владимирская область (5)	Жердевский, Балтийский, Неманский, Волоколамский, Пионерский, Азнакаевский
Арктический июль	20	7	28%	Республика Саха (Якутия) (5); Ямало-Ненецкий автономный округ (5); Чукотский автономный округ (4); Красноярский край (3)	Анадырь, Таймырский Долгано-Ненецкий, Ямальский, Верхоянский, Эгвекинот, Тазовский
Северо-восточный август	39	8	13%	Республика Саха (Якутия) (18); Забайкальский край (6); Республика Коми (2); Хабаровский край (2)	Томпонский, Среднеколымский, Красночикийский, Усть-Цилемский, Заполярный, Усть-Алданский